

Raport – Algoritm AI pentru Detecția și Analiza Evoluției Bolii Parkinson

1. Introducere

Boala Parkinson reprezintă una dintre cele mai comune afecțiuni neurodegenerative, afectând controlul motor al pacienților și având un impact major asupra calității vieții. Avansarea tehnologiilor de inteligență artificială (AI) și a metodelor de prelucrare a semnalelor biologice a deschis oportunitatea dezvoltării unor instrumente automate pentru monitorizarea evoluției bolii. Prezentul raport descrie construcția și evaluarea unui astfel de algoritm AI, bazat pe date de mers obținute prin senzori de presiune plantar, cu scopul de a detecta și clasifica stadiile bolii Parkinson.

2. Alegerea și preprocesarea datelor

Datele utilizate provin din setul de date public "Gait in Parkinson's Disease", disponibil pe Kaggle și PhysioNet. Acestea includ semnale 1D ale forței de reacție verticală (VGRF), măsurate independent pentru fiecare picior. De asemenea, sunt incluse informații demografice precum vârsta, sexul, înălțimea și greutatea pacienților.

Pentru modelele clasice de tip Random Forest, XGBoost, SVM sau KNN, au fost extrase caracteristici statistice precum media, deviația standard sau simetria pașilor. Pentru modelul avansat bazat pe rețele neuronale, semnalele brute au fost segmentate în ferestre de 100 de timpi (cu pas de 50), fiecare fereastră devenind o mostră de antrenament.

3. Metode existente (State of the Art)

Literatura de specialitate abundă în metode automate de analiză a mersului pentru detecția Parkinsonului. Primele abordări s-au bazat pe clasificatori clasici (SVM, Random Forest) antrenați pe trăsături extrase manual. De exemplu, Caramia et al. au folosit senzori inerțiali și un SVM cu kernel RBF, obținând ~75% acuratețe în clasificarea stadiilor H&Y. Alți autori, precum Balaji et al., au utilizat date VGRF și un SVM bine optimizat, obținând 98,4% acuratețe pe un set restrâns.

Progrese majore s-au realizat prin utilizarea rețelelor neuronale profunde. El Maachi et al. au introdus o arhitectură CNN 1D multi-canal, obținând o acuratețe de 85,3% în clasificarea stadiilor UPDRS. Vidya și Sasikumar au combinat CNN cu LSTM după o preprocesare EMD, atingând 98% acuratețe. Cel mai recent, Naimi et al. (2023) au propus un model ConvNet + Transformer, obținând ~88% acuratețe pe clasificarea a 4 clase (Control, H&Y 2, 2.5, 3) folosind date PhysioNet.

4. Modele clasice testate

Pentru a oferi un punct de referință, au fost testate mai multe modele clasice de machine learning pe un set de caracteristici extrase statistic:

- - Random Forest: acuratețe 76% (LOSO: 80%)
- - XGBoost: acuratețe 73% (LOSO: 75%)
- - KNN: acuratețe 77% (LOSO: 74%)
- - SVM: acuratețe 69% (LOSO: 69%)


Aceste modele au avut o performanță acceptabilă pentru clasificarea binară Parkinson vs. Control, dar nu au reușit să capteze complexitatea necesară pentru clasificarea pe stadii multiple.

5. Modelul propus

Modelul dezvoltat în cadrul acestui proiect urmează arhitectura ConvNet + Transformer, inspirată din lucrarea lui Naimi et al., cu unele modificări esențiale:

1. Preprocesare: semnalele VGRF sunt normalizate și segmentate în ferestre de 100 de timpi, cu suprapunere 50%.
2. Feature extractor CNN: pentru fiecare din cele 18 canale de semnal (senzori plantar), se aplică o rețea CNN 1D individuală, cu 2-3 straturi de convoluție + pooling.
3. Encoder temporal Transformer: pentru fiecare senzor, secvența este introdusă în encoder Transformer pentru captarea contextului pe axa timpului.
4. Encoder spațial Transformer: fuzionează vectorii obținuți din fiecare canal, analizând corelațiile dintre senzori.
5. Clasificator: un MLP cu 2 straturi dense și softmax final, cu dropout și regularizare L2.


Modelul este antrenat cu pierdere cross-entropy, optimizator Adam, early stopping și stratificare pe pacient.



Evaluare și rezultate


Rezultatele obținute arată o acuratețe per pacient de:

- 94% pentru clasificarea binară (Control vs. Parkinson);




Evaluare per pacient:

	precision	recall	f1-score	support
0	1.00	0.83	0.91	18
1	0.91	1.00	0.95	29
accuracy			0.94	47
macro avg	0.95	0.92	0.93	47
weighted avg	0.94	0.94	0.93	47




- 85% pentru clasificarea în 4 clase de severitate.



Evaluare per pacient:

	precision	recall	f1-score	support
Control	0.82	0.88	0.85	16
Mild	0.81	0.76	0.79	17
Moderate	1.00	0.89	0.94	9
Severe	0.80	1.00	0.89	4
accuracy			0.85	46
macro avg	0.86	0.88	0.87	46
weighted avg	0.85	0.85	0.85	46



Precizia este ridicată în toate clasele, iar clasa "sever" a atins ~95% precizie în ciuda unui recall mai mic (~74%). Strategia de vot majoritar pe segmente s-a dovedit eficientă în stabilizarea deciziei finale.

6. Comparație cu alte metode și perspective de îmbunătățire

Comparativ cu metodele existente din literatură, modelul propus atinge performanțe similare sau superioare, menținând o arhitectură modulară și scalabilă. Față de rețelele simple CNN sau LSTM, introducerea dublului encoder Transformer permite captarea simultană a contextului temporal și a relațiilor spațiale.

Totuși, modelul poate fi îmbunătățit prin:

- - augmentare sintetică a datelor (warping temporal, jitter);
- - oversampling pentru clasele rare;
- - antrenare pe date multianuale pentru generalizare clinică;
- - metrice adiționale de evaluare precum AUC-ROC per clasă.

7. Îmbunătățiri posibile

- - Integrarea unui modul de atenție adaptivă, care să acorde importanță variabilă senzorilor în funcție de contribuția lor la predicție;
- - Antrenarea unui encoder comun multi-senzor, în locul encoderelor individuale, pentru o mai bună fuziune a datelor;
- - Utilizarea de tehnici de augmentare mai avansate, cum ar fi mixup sau time-warping pe secvențele VGRF;
- - Transfer learning de la modele antrenate pe alte tipuri de date biomecanice;
- - Interpretabilitatea modelului: integrarea de metode SHAP sau Grad-CAM pentru a explica decizia rețelei.

8. Concluzii

Modelul ConvNet + Transformer implementat oferă performanțe superioare față de modelele clasice și rivalizează cu metodele de ultimă generație. Abordarea end-to-end, învățarea automată a trăsăturilor și integrarea atenției permit clasificarea robustă a evoluției bolii Parkinson pe baza semnalelor de mers.

9. Bibliografie

- - Naimi, S. et al. (2023). 1D-Convolutional Transformer for Parkinson disease diagnosis from gait.
- - PhysioNet Gait in Parkinson's Disease Dataset.
<https://physionet.org/content/gaitpdb/1.0.0/>
- - Kaggle: <https://www.kaggle.com/datasets/zarif98sjs/gait-in-parkinsons-disease>