

Raport - Dezvoltare algoritm AI pentru detecția și analiza evoluției bolii Parkinson

1. Introducere

Boala Parkinson reprezintă una dintre cele mai comune afecțiuni neurodegenerative, afectând controlul motor al pacienților și având un impact major asupra calității vieții. Avansarea tehnologiilor de inteligență artificială (AI) și a metodelor de prelucrare a semnalelor biologice a deschis oportunitatea dezvoltării unor instrumente automate pentru monitorizarea evoluției bolii. Prezentul raport descrie construcția și evaluarea unui astfel de algoritm AI, bazat pe date de mers obținute prin senzori de presiune plantar, cu scopul de a detecta și clasifica stadiile bolii Parkinson.

2. Alegerea și preprocesarea setului de date

Datele utilizate provin din setul de date public Gait in Parkinson's Disease, disponibil pe PhysioNet și Kaggle. Acestea includ semnale unidimensionale ale forței de reacție verticală (Vertical Ground Reaction Force – VGRF), măsurate independent pentru fiecare picior, folosind câte 8 senzori sub fiecare talpă (în total 16 canale per subiect). De asemenea, sunt incluse informații demografice precum vârsta, sexul, înălțimea și greutatea pacienților. Datele brute au fost normalizate și segmentate în ferestre de 100 de timpi (cu suprapunere de 50%) pentru a genera mostre de antrenament din semnalele continue.

Pentru modelele clasice de clasificare (ex. Random Forest, XGBoost, SVM, KNN), au fost extrase caracteristici statistice din semnalele VGRF, precum media, deviația standard sau simetria pașilor. Simetria pașilor a fost calculată ca un indice care compară distribuția forțelor la nivelul piciorului stâng și drept. Concret, am definit un indice de simetrie a mersului pe baza diferenței relative dintre o metrică a pașilor stâng vs. drept (de exemplu, forța totală pe talpa stângă vs. dreaptă):

$$S = \frac{|X_{\text{stâng}} - X_{\text{drept}}|}{X_{\text{stâng}} + X_{\text{drept}}} \times 100\%$$

unde $X_{\text{stâng}}$ și X_{drept} reprezintă valoarea medie a forței maxime pe pas (sau alt parametru relevant) pentru piciorul stâng, respectiv drept. Un astfel de indice $S=0$ indică un mers perfect simetric, în timp ce valori mai mari evidențiază asimetria între pașii celor două picioare. Această caracteristică oferă informații despre eventuale diferențe în modul de călcare (ex. un pacient poate exercita o forță mai mare pe un picior decât pe celălalt din cauza simptomelor). Pentru modelul avansat bazat pe rețele neuronale, în loc de a extrage manual trăsături, s-au folosit direct segmentele brute ale semnalelor normalizate ca intrare în rețea, fiecare fereastră (100 de puncte de timp) fiind considerată o mostră de antrenament.

3. Metode existente (State of the Art)

Literatura de specialitate abundă în metode automate de analiză a mersului pentru detecția și stadializarea Parkinson-ului. Primele abordări s-au bazat pe clasificatori clasici antrenați pe trăsături extrase manual. De exemplu, **Caramia et al.** au folosit senzori inerțiali portabili și un clasificator SVM cu kernel RBF pentru a diferenția stadiile Hoehn & Yahr (H&Y) ale bolii, obținând o acuratețe de ~75%. Alți autori, precum **Balaji et al.**, au utilizat date VGRF și un SVM optimizat, raportând ~98,4% acuratețe în clasificarea severității Parkinson pe un set de date restrâns.

Progrese majore s-au realizat ulterior prin utilizarea rețelelor neuronale profunde, care pot învăța automat caracteristici din datele de mers. **El Maachi et al.** au introdus o arhitectură CNN 1D multi-canal (18 canale VGRF în paralel) și au validat-o pe clasificarea severității după scala UPDRS, obținând ~85,3% acuratețe. **Vidya și Sasikumar (2022)** au propus o abordare bazată pe decompunerea semnalelor prin *Empirical Mode Decomposition* (EMD), urmată de un lanț hibrid CNN-LSTM; modelul lor a atins ~88% acuratețe în predicția stadiului bolii Parkinson pe 4 clase (inclusiv control). Cea mai recentă direcție îmbină arhitecturi de tip Convoluțional cu mecanisme de atenție. **Naimi et al. (2023)** au propus un model hibrid ConvNet + Transformer pentru diagnosticul Parkinson pe baza mersului, exploatând atât extragerea locală de trăsături prin CNN, cât și dependențele pe termen lung prin transformare. Arhitectura lor a obținut ~88% acuratețe pe setul de date PhysioNet, depășind alte metode contemporane pe același set. Aceste rezultate din literatură sugerează potențialul ridicat al rețelelor neurale profunde (inclusiv modele hibride) în analiza gait-ului pacienților cu Parkinson.

4. Modele clasice testate

Pentru a oferi un punct de referință, au fost antrenate și evaluate mai multe modele clasice de machine learning pe setul de caracteristici statistice extrase (inclusiv indicele de simetrie menționat anterior). Performanțele obținute pentru clasificarea binară Parkinson vs. Control au fost următoarele:

- **Random Forest:** acuratețe ~76% (LOSO: 80%)
- **XGBoost:** acuratețe ~73% (LOSO: 75%)
- **KNN:** acuratețe ~77% (LOSO: 74%)
- **SVM (RBF):** acuratețe ~69% (LOSO: 69%)

În paranteză sunt indicate rezultatele obținute prin validare de tip **LOSO** (Leave-One-Subject-Out). Această metodă presupune antrenarea modelului pe toți subiecții mai puțin unul, subiectul lăsat pe dinafară fiind folosit pentru test; procedura se repetă astfel încât fiecare subiect din date să fie folosit o dată ca set de test. Evaluarea LOSO oferă o estimare mai strictă a generalizării, asigurând că modelul este testat de fiecare dată pe un pacient complet nou (nevăzut în antrenare). Modelele clasice de mai sus au obținut performanțe rezonabile pentru clasificarea binară (diferențierea pacienților Parkinson de control), însă acuratețea lor a scăzut semnificativ când s-a încercat clasificarea pe stadii multiple de severitate. Acest fapt indică dificultatea metodelor bazate pe trăsături simple de a surprinde complexitatea tiparelor de mers asociate diferitelor stadii ale bolii Parkinson.

5. Modelul Propus

Modelul dezvoltat în cadrul acestui proiect urmează o arhitectură hibridă **ConvNet + Transformer**, inspirată din lucrarea lui Naimi et al. menționată anterior, însă cu unele modificări esențiale. În loc să se bazeze exclusiv pe o singură rețea neuronală, modelul nostru îmbină un extractor de caracteristici de tip convoluțional (pentru a extrage trăsături locale din semnale) cu două module Transformer (pentru a capta dependențele temporale și relațiile spațiale). Schema arhitecturală, împreună cu principalii săi parametri, este descrisă mai jos:

1. Preprocesare: Semnalele VGRF de intrare (16 canale individuale + 2 canale sumă per picior) sunt normalizate (scala standard) și segmentate în ferestre de 100 de puncte de timp, cu suprapunere de 50% între ferestre consecutive. Astfel, fiecare fereastră temporală servește ca eșantion de antrenament, fiind etichetată conform stării (control sau stadiu Parkinson) a subiectului din care provine.


2. Extractor de trăsături (CNN 1D pe canal): Pentru fiecare dintre cele 18 canale de semnal (16 senzori plantari individuali + 2 semnale integrale pe picior) se aplică o rețea neuronală de tip CNN 1D independentă. Fiecare astfel de sub-rețea are 2-3 straturi de convoluție alternând cu straturi de pooling, cu funcții de activare ReLU. În experiment, am utilizat filtre de dimensiuni mici (kernel de lungime 3-5 timpi) pentru a surprinde formele locale ale semnalului. Numărul de filtre a crescut gradual pe măsură ce adâncimea rețelei a crescut (ex: 32 de filtre în primul strat, 64 în al doilea). **Pooling-ul** (de ex. max-pooling pe fereastră de lungime 2) reduce dimensiunea temporală după fiecare strat convoluțional, iar la final, fiecare sub-rețea CNN produce un vector de caracteristici latent pentru canalul corespunzător. Acest modul acționează ca un extractor de trăsături locale, separat pentru fiecare senzor, permițând învățarea unor reprezentări adecvate fiecărui canal de intrare.

3. Encoder temporal (Transformer pe fiecare canal): Secvența de vectori de trăsături produsă de CNN pentru fiecare senzor este apoi introdusă într-un encoder Transformer dedicat aceluși senzor. Acest modul folosește mecanisme de **atenție** pentru a modela dependențele pe termen lung de-a lungul timpului în cadrul semnalului aceluși senzor. În implementare, encoderul temporal constă dintr-un bloc Transformer cu mai multe capete de atenție (*multi-head self-attention*) și feed-forward intern. Rolul său este de a acorda ponderi diferite momentelor cheie din secvența temporală și de a genera o reprezentare temporală *contextualizată* a semnalului, în care fiecare element (timp) „vede” întregul istoric al aceluși canal. Rezultatul fiecărui encoder temporal este un vector caracteristic comprimat pentru senzorul respectiv, care sumarizează informația pe întreaga fereastră de timp, ținând cont de structura temporală.

4. Encoder spațial (Transformer pe ansamblul de canale): Următorul modul fuzionează informația provenită de la toți senzorii. Practic, vectorii obținuți de la encoder-ele temporale pentru fiecare dintre cele 18 canale sunt considerați ca o *secvență* de intrări și sunt trecuți printr-un al doilea encoder Transformer, de această dată pe axa senzorilor. Acest **encoder spațial** aplică atenție multi-head peste setul de canale, analizând corelațiile și relațiile dintre diferiții senzori (inclusiv între piciorul stâng și drept, zone ale tălpii, etc.). Astfel, modelul poate învăța ce senzori sau zone plantare aduc informație mai importantă pentru diagnostic și cum variațiile de presiune se corelează între picioare. Encoderul spațial produce o reprezentare combinată a întregului set de senzori pentru fereastra de timp analizată – în esență un vector de caracteristici global, ce înglobează atât contextul temporal, cât și pe cel spațial (la nivel de amprentă plantar).

5. Clasificator (rețea neuronală densă): Vectorul global obținut este apoi introdus într-un *Multi-Layer Perceptron* (MLP) pentru realizarea deciziei de clasificare. Clasificatorul constă din 2 straturi dense complet conectate, urmate de un strat final de ieșire cu activare *softmax*. Primul strat dens (strat ascuns) are un număr moderat de neuroni (în experiment ~ 64 neuroni) și folosește funcția de activare ReLU. Al doilea strat dens produce scorurile pentru fiecare clasă (2 neuroni pentru varianta binară Control/Parkinson, sau 4 neuroni pentru clasificarea pe 4 clase), aceste scoruri fiind apoi normalizate cu softmax pentru a obține probabilități pe clase. Pentru a preveni supraantrenarea, în cadrul MLP s-au aplicat tehnici de **regularizare**: *dropout* (cu rata 0.5, renunțând aleator la 50% dintre neuroni în timpul antrenamentului) și penalizare L2 a ponderilor (regularizare ridge cu un coeficient λ mic, ~ 0.001). Aceste metode ajută la evitarea supra-potivirii datelor de antrenament, conferind modelului o mai bună capacitate de generalizare.

După definirea arhitecturii de mai sus, modelul a fost **antrenat** folosind datele preprocesate din PhysioNet/Kaggle. Ca funcție de pierdere s-a folosit entropia încrucișată categoriată (*categorical cross-entropy*), adecvată pentru sarcina de clasificare multi-clasă. Optimizarea s-a realizat cu algoritmul **Adam** (Adaptive Moment Estimation), cu o rată de învățare inițială setată la 0,001. Antrenarea a fost efectuată pe mini-batch-uri (dimensiunea batch-ului ~ 32) și s-a folosit o strategie de **early stopping**: împărțind datele în antrenament și validare, am monitorizat pierderea pe setul de validare și am oprit antrenarea după ce performanța nu s-a mai îmbunătățit timp de un număr de epoci (pentru a preveni overfitting). De asemenea, am asigurat o stratificare pe subiecți în împărțirea datelor: segmentele provenite de la un anumit subiect au fost incluse integral fie în antrenament, fie în test, pentru ca evaluarea să reflecte capacitatea de generalizare la pacienți noi (abordare utilizată și la validarea LOSO de mai sus).



6. Evaluare si Rezultate

Figura 1 – Accuracy si Loss pe Clasificare Binara




Figura 2 – Accuracy si Loss pe Clasificare Severitate




Figura 3 – Matrice Confuzie Clasificare Binara

Evaluare per pacient:				
	precision	recall	f1-score	support
0	1.00	0.83	0.91	18
1	0.91	1.00	0.95	29
accuracy			0.94	47
macro avg	0.95	0.92	0.93	47
weighted avg	0.94	0.94	0.93	47

Matrice de Confuzie - Clasificare binară per pacient





Figura 4 – Matrice Confuzie Clasificare Severitate

Evaluare per pacient:				
	precision	recall	f1-score	support
Control	0.82	0.88	0.85	16
Mild	0.81	0.76	0.79	17
Moderate	1.00	0.89	0.94	9
Severe	0.80	1.00	0.89	4
accuracy			0.85	46
macro avg	0.86	0.88	0.87	46
weighted avg	0.85	0.85	0.85	46

Matrice de Confuzie - Clasificare în 4 clase per pacient



Matricea de confuzie pentru **clasificarea binară** (Control vs. Parkinson). Modelul reușește o separare aproape perfectă a celor două categorii, după cum se vede prin faptul că valorile dominante sunt în cele două celule diagonale (predicții corecte: Control clasificat ca *Control* și Parkinson clasificat ca *Parkinson*). Ratele de eroare (false alarme sau omisiuni) sunt foarte scăzute, ceea ce corespunde acurateții de ~94% raportate.

Matricea de confuzie obținută pe setul de test pentru **clasificarea celor patru clase** (Control, H&Y 2, 2.5, 3). Valorile de pe diagonala principală (predicții corecte) sunt semnificativ mai mari decât valorile off-diagonale, indicând performanța bună a modelului pe fiecare clasă. De exemplu, modelul identifică foarte bine subiecții sănătoși (Control) și pe cei în stadiul H&Y 3 (Sever), cu puține confuzii. Confuziile care apar se manifestă în special între clasele adiacente (H&Y 2 vs. H&Y 2.5), ceea ce sugerează că modelul tinde să greșească doar în cazurile limită, de graniță între stadii.

În Figura 1 și Figura 2 sunt prezentate curbele de evoluție a funcției de pierdere și a acurateței în timpul antrenării modelului, atât pentru setul de antrenament, cât și pentru setul de validare. Se observă că pierderea (loss) scade treptat și se stabilizează către finalul antrenării, în timp ce acuratețea crește și atinge un plafon. Acest lucru indică o convergență corespunzătoare a modelului, fără semne evidente de supra-antrenare: curba pierderii de validare urmează îndeaproape pierderea de antrenament, iar acuratețea de validare se apropie de cea de antrenament, sugerând că modelul generalizează bine.

Figura 1. Curba funcției de pierdere (*loss*) în timpul antrenării, pentru datele de antrenament și validare. Se observă scăderea continuă a pierderii până la convergență, fără creșteri semnificative spre final, semn că nu apare overfitting.

Figura 2. Evoluția acurateței clasificării pe parcursul antrenării, atât pentru setul de antrenament, cât și pentru cel de validare. Modelul ajunge la o acuratețe ridicată, curbele indicând un plafon spre finalul antrenamentului – semn că rețeaua și-a optimizat învățarea și nu mai aduce îmbunătățiri substanțiale după un anumit număr de epoci.

Evaluarea finală s-a realizat pe subiecții din setul de test (disjunct față de antrenament). Rezultatele obținute arată o **acuratețe per pacient** de:

- **94%** pentru clasificarea binară (*Control vs. Parkinson*);
- **85%** pentru clasificarea în **4 clase** de severitate (Control, H&Y 2, 2.5, 3).

Precizia modelului este ridicată pe toate clasele, conform matricelor de confuzie ilustrate în Figura 3 și Figura 4.

Figura 3 prezintă matricea de confuzie pentru sarcina binară Control vs. Parkinson, confirmă că modelul distinge aproape perfect subiecții sănătoși de pacienții cu Parkinson – rata de eroare fiind foarte mică în acest caz (număr minim de fals pozitive sau fals negative). Per ansamblu, aceste rezultate demonstrează capacitatea modelului de a **clasifica robust evoluția bolii** pe baza semnalelor de mers.

Figura 4 prezintă matricea de confuzie pentru clasificarea multclasă (4 clase de severitate), în care elementele diagonale (predicții corecte) au valori predominant mari. Se poate observa că modelul diferențiază bine fiecare categorie: de pildă, clasa *Sever* (Hoehn & Yahr 3) atinge 80% precizie (precision), deși are un recall ridicat (100%) – ceea ce înseamnă că, deși aproape toate instanțele prezise ca *Sever* sunt corecte, există unele cazuri reale de stadiu Mild pe care modelul le-a clasificat ca stadii mai grele. Cea mai notabilă confuzie apare între stadiile adiacente H&Y 2 și H&Y 2.5, ceea ce era de așteptat dată fiind similitudinea clinică între aceste niveluri intermediare. În schimb, clasele extremă *Control* (sănătos) și *Sever* (H&Y 3) sunt cel mai bine separate de restul.

Merită menționat că, pentru a obține scorurile de acuratețe la nivel de pacient (menționate mai sus), am folosit o strategie de **vot majoritar pe segmente**. Cu alte cuvinte, cum un pacient poate avea multiple segmente (ferestre) extrase dintr-o înregistrare de mers, se realizează mai întâi predicția pe fiecare segment, apoi pacientul este atribuit clasei votate de majoritatea segmentelor sale. Această tehnică a avut efect de stabilizare a deciziei finale pe pacient, reducând variabilitatea datorată segmentelor individuale și mărin­d acuratețea per pacient în raport cu evaluarea directă pe segmente izolate.

7. Comparație cu alte metode și perspective de îmbunătățire

Comparativ cu metodele existente din literatură, modelul propus atinge performanțe similare sau superioare, menținând în același timp o arhitectură modulară și scalabilă. În particular, abordarea noastră se aseamănă cu cea a lui **Naimi et al. (2023)**, care au combinat tot rețele CNN 1D cu encodere Transformer pentru date VGRF și au raportat ~88% acuratețe pe clasificarea stadiilor Parkinson – valoare foarte apropiată de cea obținută de modelul nostru (85% pe 4 clase, respectiv 94% pe sarcina mai ușoară de clasificare binară). De asemenea, **Nguyen et al. (2022)** au propus o arhitectură în care informația temporală și cea spațială sunt decuplate prin doi transformeri (similar conceptului din modelul nostru), urmată de două straturi fully-connected și ieșirea finală. Pe setul PhysioNet, modelul lor a atins ~95,2% acuratețe în distingerea pacienților Parkinson de controale sănătoase, depășind metodele anterioare bazate pe caracteristici hand-crafted. Modelul nostru (94% pe aceeași sarcină binară) rivalizează practic cu acest state-of-the-art în detectarea Parkinson-ului, având avantajul că abordează și problema mai dificilă a clasificării pe stadii multiple.

Față de rețelele clasice CNN sau LSTM utilizate individual, introducerea **dublului encoder Transformer** în arhitectura noastră permite captarea simultană atât a contextului temporal (prin encoderul pe secvență de timp), cât și a relațiilor spațiale dintre senzori (prin encoderul pe setul de senzori). Această fuziune atențională bi-dimensională conduce la o reprezentare internă mai bogată a datelor de mers, contribuind la creșterea acurateței modelului. Practic, modelul end-to-end învață automat trăsături relevante și le integrează într-un mod pe care metodele bazate doar pe CNN (care captează mai mult local) sau doar pe rețele recurente (care pot pierde detalii spațiale) nu îl pot realiza separat.

Totuși, modelul poate fi în continuare îmbunătățit prin diverse strategii, atât la nivel de date, cât și la nivel de arhitectură sau antrenare, după cum urmează:

- **Augmentarea datelor:** Generarea sintetică de noi exemple din cele existente poate crește robustețea modelului. Tehnici de augmentare temporală, precum time-warping (dilatarea sau comprimarea aleatoare a axei de timp) sau adăugarea de zgomot (jitter) în semnale, pot ajuta la simularea variabilității inter-pacient și la evitarea supra-antrenării pe un set limitat de subiecți.
- **Echilibrarea claselor:** În cazul clasificării pe stadii, anumite clase (de exemplu, stadiile intermediare H&Y 2.5) pot fi sub-reprezentate în date. Tehnici de **oversampling** (supra-eșantionare) a instanțelor din clasele rare sau generarea de exemple sintetice (ex. cu SMOTE) ar putea asigura un antrenament mai echilibrat al rețelei.
- **Mai multe date longitudinale:** Antrenarea și validarea pe seturi de date extinse, ideal colectate de-a lungul mai multor ani pentru aceiași pacienți, ar putea îmbunătăți generalizarea clinică. Un model antrenat pe date multi-anuale ar învăța variabilitatea progresiei bolii în timp și ar putea oferi predicții mai robuste în scenarii reale de monitorizare pe termen lung.
- **Metrici adiționale de evaluare:** În afara acurateței și a matricilor de confuzie, ar fi utilă calcularea unor metrici precum **AUC-ROC** (aria de sub curba ROC) pentru fiecare clasă, sensibilitate, specificitate, scor F1 etc. Aceste metrici adiționale ar oferi o imagine mai detaliată asupra performanței modelului pe fiecare categorie (de exemplu, cât de bine detectează modelul în mod specific stadiul Sever vs. Moderat).

8. Îmbunătățiri posibile

Privind spre viitor, există numeroase direcții de dezvoltare a acestui algoritm AI, pe lângă cele menționate mai sus. Câteva îmbunătățiri posibile includ:

- **Atenție adaptivă pe senzori:** Integrarea unui modul de atenție adaptivă care să acorde importanță variabilă fiecărui senzor în funcție de contribuția sa la predicție. De exemplu, modelul ar putea învăța să “ignore” zgomotul sau datele neinformative de la un anumit senzor dacă alți senzori oferă indicii mai clare despre stadiul pacientului. Acest lucru ar crește **interpretabilitatea** și ar putea crește performanța, concentrând atenția modelului pe regiunile relevante ale tălpii (ex: senzorii de la călcâi vs. vârf, în funcție de tiparul de mers al pacientului).
- **Encoder comun multi-senzor:** În locul folosirii de encodere separate pe fiecare canal urmate de un encoder spațial, s-ar putea experimenta cu un **encoder unic** care să primească direct toate canalele (de exemplu, tratând cei 18 senzori x 100 timp ca o matrice intrare 18x100). Acest encoder 2D (pe care l-am putea vedea ca pe un Transformer ori CNN cu atenție pe un “imagini” de 18x100) ar putea învăța simultan caracteristici spațio-temporale, potențial mai eficient decât doi pași separați. Totuși, un astfel de model ar fi mai complex și ar necesita mai multe date pentru antrenare.
- **Augmentare avansată a secvențelor:** Pe lângă augmentările simple (jitter, warping) deja discutate, se pot aplica tehnici mai avansate precum *mixup* (combinarea a două semnale diferite într-unul nou, ca un amestec) sau augmentare prin reordonarea secvențelor. De exemplu, *window slicing* și recombinarea segmentelor din semnal ar putea genera variații noi de mers. Astfel de tehnici s-au dovedit utile în alte probleme de clasificare de secvențe și ar putea crește capacitatea de generalizare a modelului la tipare de mers ușor diferite.
- **Transfer learning:** Utilizarea cunoștințelor din modele pre-antrenate pe alte tipuri de date biomecanice. De exemplu, un model pre-antrenat pe detecția altor afecțiuni de mers sau pe date de accelerometrie ar putea servi ca punct de plecare (inițializare a parametrilor) pentru modelul nostru, necesitând apoi doar o recalibrare (*fine-tuning*) pe setul de date Parkinson. Transferul de învățare ar putea fi benefic mai ales dacă avem acces la date limitate, permițând modelului să pornească de la un nivel înalt de abstractizare a caracteristicilor.
- **Interpretabilitate mai bună:** Integrarea unor metode post-hoc de explicare a deciziilor rețelei, precum **SHAP** (SHapley Additive exPlanations) sau **Grad-CAM** (Gradient-weighted Class Activation Mapping), ar fi de mare valoare. Aceste tehnici ar putea evidenția, de exemplu, ce secvențe din semnal (sau ce senzori) au influențat cel mai mult decizia modelului pentru un anumit pacient. În context clinic, un astfel de nivel de interpretare ar putea crește încrederea medicilor în utilizarea modelului, arătând concret *de ce* algoritmul a estimat că un pacient este într-un anumit stadiu al bolii pe baza mersului (de ex., dacă modelul se uită la lipsa de simetrie între picioare sau la scăderea forței pe vârful piciorului etc.).

Prin implementarea unora dintre aceste idei, algoritmul propus ar putea deveni și mai precis, robust și util din punct de vedere clinic, facilitând monitorizarea evoluției bolii Parkinson într-un mod neinvaziv și automat.

9. Concluzii

Modelul hibrid **ConvNet + Transformer** implementat oferă performanțe superioare față de modelele clasice testate și rivalizează cu metodele de ultimă generație din literatură. Abordarea end-to-end propusă, cu învățarea automată a trăsăturilor și integrarea mecanismelor de atenție, permite o clasificare robustă a evoluției bolii Parkinson pe baza semnalelor de mers, demonstrând potențialul tehnicilor de deep learning în domeniul analizei tulburărilor de mers. Rezultatele foarte bune obținute (94% acuratețe pe diagnostic binar și 85% pe clasificarea severității) confirmă că un astfel de algoritm poate asista eficient clinicienii, oferind o evaluare obiectivă și reproductibilă a stării pacienților și a progresiei bolii, cu aplicabilitate în monitorizarea pe termen lung și în studii clinice viitoare.

10. Bibliografie

- **Balaji, E., Brindha, D., Elumalai, V. K., Umesh, K.** (2021). *Data-driven gait analysis for diagnosis and severity rating of Parkinson's disease*. **Medical Engineering & Physics**, **91**, 54–64. doi:10.1016/j.medengphy.2021.03.005 pubmed.ncbi.nlm.nih.gov
- **Caramia, C., Torricelli, D., Schmid, M., Muñoz-Gonzalez, A., Gonzalez-Vargas, J., Grandas, F., et al.** (2018). *IMU-Based Classification of Parkinson's Disease From Gait: A Sensitivity Analysis on Sensor Location and Feature Selection*. **IEEE Journal of Biomedical and Health Informatics**, **22**(6), 1765–1774. doi:10.1109/JBHI.2018.2795940
- **El Maachi, I., Bilodeau, G-A., Bouachir, W.** (2020). *Deep 1D-ConvNet for accurate Parkinson disease detection and severity prediction from gait*. **Expert Systems with Applications**, **143**, 113075. doi:10.1016/j.eswa.2019.113075 pmc.ncbi.nlm.nih.gov
- **Naimi, S., Bouachir, W., Bilodeau, G-A.** (2023). *1D-Convolutional Transformer for Parkinson disease diagnosis from gait*. **Neural Computing & Applications**, **36**(4), 1947–1957. doi:10.1007/s00521-023-09193-6 arxiv.org
- **Nguyen, D. M. D., Miah, M., Bilodeau, G-A., Bouachir, W.** (2022). *Transformers for 1D signals in Parkinson's disease detection from gait*. **arXiv preprint arXiv:2204.00423** arxiv.labs.arxiv.org
- **Vidya, B., Sasikumar, P.** (2022). *Parkinson's disease diagnosis and stage prediction based on gait signal analysis using EMD and CNN-LSTM network*. **Engineering Applications of Artificial Intelligence**, **114**, 105099. doi:10.1016/j.engappai.2022.105099 [rpscienceshub.com](https://www.rpscienceshub.com)
- **PhysioNet Gait in Parkinson's Disease Dataset** (Goldberger et al., 2012). Disponibil online: <https://physionet.org/content/gaitpdb/1.0.0>
- **Kaggle – Gait in Parkinson's Disease Data Set** (Zhang, 2018). Disponibil online: <https://www.kaggle.com/datasets/zarif98sjs/gait-in-parkinsons-disease>