

Raport - Dezvoltare algoritm AI pentru detecția și analiza evoluției bolii Parkinson

Introducere

Acest raport prezintă dezvoltarea unui algoritm AI pentru detecția și analiza evoluției bolii Parkinson folosind datele de mers obținute de la senzori de presiune. Scopul este construirea unui instrument automatizat, precis și scalabil care poate fi utilizat pentru monitorizarea pacienților și diferențierea între stadii ale bolii.

1. Alegerea și preprocesarea setului de date

Setul de date utilizat a fost preluat de pe Kaggle (<https://www.kaggle.com/datasets/zarif98sjs/gait-in-parkinsons-disease>) și conține date de mers (semnale 1D de presiune) provenite de la pacienți sănătoși și pacienți diagnosticați cu Parkinson. Datele includ forțele totale aplicate pe piciorul stâng și drept, precum și date demografice (vârstă, sex, înălțime, greutate).

Pentru modelele simple, s-au extras caracteristici statistice precum media, deviația standard, numărul de pași detectați și simetria pașilor, care au fost folosite ca input pentru algoritmi clasici de Machine Learning.

Pentru modelul complex, s-au segmentat datele brute în ferestre de 100 de timpi, cu pas de 50, iar fiecare fereastră a fost folosită ca input 2D într-un model bazat pe rețele convoluționale (ConvNet) și atenție (Transformer).

2. Construirea și antrenarea modelelor AI

Au fost dezvoltate două abordări distincte:

- A. Modele clasice (Random Forest, XGBoost, SVM, KNN)

Aceste modele au fost antrenate pe un set de trăsături statistice extrase din semnalele de mers. Datele au fost împărțite în seturi de antrenare și testare (sau validate cu Leave-One-Subject-Out), iar performanța a fost evaluată cu metrici standard: acuratețe, precizie, recall și f1-score.

- B. Model complex: Conv1D + Transformer

Acest model primește ca input secvențe 1D (100x18 - unde 18 este numărul senzorilor) și folosește o combinație de straturi convoluționale și atenție multi-head pentru a învăța automat trăsături relevante. S-au implementat tehnici pentru a reduce overfitting-ul: regularizare L2, Dropout, EarlyStopping și ReduceLROnPlateau.

3. Testarea și evaluarea modelelor

- Rezultate modele simple (binare):

- Random Forest : Acuratete 76%
- XGBoost : Acuratete 73%
- KNN : Acuratete 77%
- SVM : Acuratete 69%




- Random Forest (LOSO): Acuratețe 80%
- XGBoost (LOSO): Acuratețe 75%
- KNN (LOSO): Acuratețe 74%
- SVM (LOSO) : Acuratete 69%

- Rezultate model complex (binar):

- Conv1D + Transformer: Acuratețe per pacient = 94

Evaluare per pacient:		precision	recall	f1-score	support
	0	1.00	0.83	0.91	18
	1	0.91	1.00	0.95	29
accuracy				0.94	47
macro avg		0.95	0.92	0.93	47
weighted avg		0.94	0.94	0.93	47

Matrice de Confuzie - Clasificare binară per pacient






- Rezultate model complex (4 clase):

- Acuratețe per pacient = 85%.

-Precizie bună pentru toate clasele (Control, Mild, Moderate, Severe)

Evaluare per pacient:				
	precision	recall	f1-score	support
Control	0.82	0.88	0.85	16
Mild	0.81	0.76	0.79	17
Moderate	1.00	0.89	0.94	9
Severe	0.80	1.00	0.89	4
accuracy			0.85	46
macro avg	0.86	0.88	0.87	46
weighted avg	0.85	0.85	0.85	46



4. Concluzii și recomandări

Modelul Conv1D + Transformer se dovedește a fi semnificativ mai performant decât modelele clasice, atât în clasificarea binară, cât și în analiza evoluției (clasificare pe 4 clase).

Bibliografie

1. Naimi, S. et al. (2023). 1D-Convolutional Transformer for Parkinson disease diagnosis from gait.
2. PhysioNet. Gait in Parkinson's Disease Dataset. <https://physionet.org/content/gaitpdb/1.0.0/>